

Informazione e sua misura

Marco Lops

lops@unina.it

<https://docenti.unina.it/marco.lops>

Informatica e Informazione

Da Wikipedia: L'informatica è la scienza che si occupa del trattamento dell'informazione mediante procedure automatizzate, avendo in particolare per oggetto lo studio dei fondamenti teorici dell'informazione, della sua computazione a livello logico e delle tecniche pratiche per la sua implementazione e applicazione in sistemi elettronici automatizzati detti quindi sistemi informatici. Ma:

- 1 Cos'è l'Informazione?
- 2 Una volta definita formalmente l'informazione, come la si misura?
- 3 Esiste un legame diretto tra la "quantità di informazione" e le risorse (hardware e software) necessarie per "trattarla" (cioè trasferirla, memorizzarla, ecc.?)

Cominciamo con un esempio riguardo a 3)

- Supponiamo di avere una sorgente quaternaria (la cui emissione sia schematizzata mediante una variabile $X \in \mathcal{X} = \{0, 1, 2, 3\}$;
- Supponiamo di indicare con $X(n)$ l' n -ma emissione della sorgente;
- Su lunghe stringhe di simboli, possiamo valutare la frequenza di occorrenza di ciascuna cifra che, al limite per $n \rightarrow \infty$, tende alla probabilità.
- Sia allora $p_{X(n)}(x) = p_X(x)$, $x \in \mathcal{X}$ la pmf della generica emissione e assumiamo:

$$p_X(x) = \begin{cases} \frac{1}{2} & x = 0 \\ \frac{1}{4} & x = 1 \\ \frac{1}{8} & x = 2 \\ \frac{1}{8} & x = 3 \end{cases} \quad (1)$$

Esempio (continuazione)

- Ogni simbolo quaternario può essere rappresentato mediante una coppia di bit;
- Questo significa che, indipendentemente dal simbolo emesso, avremo un codice di lunghezza 2 bits/simbolo;
- Cambiamo ora approccio: usiamo, cioè, un codice a lunghezza variabile quale quello sotto indicato in prima colonna e confrontiamolo con il codice a lunghezza fissa

x	C_{fissa}	$C_{\text{variabile}}$
0	00	0
1	01	10
2	10	110
3	11	111

Esempio (continuazione)

- Supponiamo ora che la sorgente emetta una (lunga) stringa di N simboli;
- con il codice a lunghezza fissa, come detto, useremo 2 bit/simbolo;
- Con il codice a lunghezza variabile, indicando con $f_N(i)$ la frequenza con cui nella stringa appare la lettera i , avremo invece che il *numero medio* di bits su simbolo è

$$L_N = f_N(0) + 2f_N(1) + 3f_N(2) + 3f_N(3) \longrightarrow$$

$$p_X(0) + 2p_X(1) + 3p_X(2) + 3p_X(3) = L = 1.75 \quad \text{bit/simbolo}$$

- Il codice a lunghezza variabile precedente ha anche altre caratteristiche che ne rendono possibile l'univoca decifrabilità. La domanda che ci poniamo ora è:
Come mai?
- La risposta è che la mia sorgente emette meno informazione di quella che corrisponderebbe ad una lunghezza media del codice di 2 bits/simbolo.

L'informazione: Ipotesi "di senso comune"

- Supponiamo che gli eventi di interesse siano $(A_1, \dots, A_N)$, i.e. N , sottoinsiemi di un certo spazio campione Ω ;
- Si consideri lo spazio di probabilità $(\Omega, \mathcal{T}, \mathbb{P})$ con $\mathcal{T}$ costruito a partire dagli eventi di interesse;
- Sia $A \in \mathcal{T}$ un evento del cui verificarsi siamo informati: vogliamo definire $i(A)$, la quantità di informazione che riceviamo sapendo che A si verifica;
- Ipotesi "sensate" nella definizione di $i(A)$ sono:
 - Non negatività L'informazione non può nuocere $i(A) \geq 0$;
 - Eventi rari Un'informazione che concerna il verificarsi di eventi rari ha maggior valore, cioè $i(A)$ è funzione decrescente di $\mathbb{P}(A)$
 - Indipendenza Se A, B sono indipendenti, $i(A \cap B) = i(A) + i(B)$.
- Conseguenza:

$$i(A) \stackrel{\text{def}}{=} \log \frac{1}{\mathbb{P}(A)}$$

Informazione media

- Assumiamo di eseguire ripetutamente un esperimento che abbia esiti possibili $\{A_1, \dots, A_N\}$;
- Siano $\{\mathbb{P}(A_i)\}_{i=1}^N$ le corrispondenti probabilità;
- Ovviamente $i(A)$ è una variabile aleatoria, rappresentata dalla funzione

$$i : A \in \{A_1, \dots, A_N\} \longrightarrow i(A) = \log \frac{1}{\mathbb{P}(A)} \in [0, +\infty[$$

- The average value of $i(A)$ is thus

$$\mathbb{E}[i(A)] = \sum_{A \in \{A_1, \dots, A_N\}} \mathbb{P}(A) \log \frac{1}{\mathbb{P}(A)}$$

- La quantità $H(\mathcal{E}) = \mathbb{E}[i(A)]$ si definisce **entropia** dell'esperimento aleatorio i cui possibili risultati sono $\{A_1, \dots, A_N\}$.

Entropia di una variabile aleatoria discreta

- Sia X una variabile aleatoria che assuma valori in un alfabeto $\mathcal{X}$. Per il momento, si supponga che $|\mathcal{X}| = M$ e $\mathcal{X} = \{x_1, \dots, x_M\}$.
- Gli eventi di interesse ora sono $\{X = x_i\}_{i=1}^M$;
- Possiamo quindi definire la variabile aleatoria

$$i(X) = \log \left[\frac{1}{p_X[X(\omega)]} \right]$$

- Si definisce **entropia** di X la quantità

$$H(X) = \mathbb{E}[i(X)] = \sum_{i=1}^M p_X(x_i) \log \frac{1}{p_X(x_i)}$$

La definizione si applica anche al caso in cui $M \rightarrow \infty$

Alcuni commenti

- La base del logaritmo determina l'unità di misura dell'entropia. In particolare, l'entropia si misura in
 - † **bit**, se la base del logaritmo è 2;
 - † **nat**, se la base del logaritmo è e (logaritmo neperiano);
- La quantità media di informazione che noi riceviamo osservando le determinazioni di una variabile aleatoria è *a fortiori* pari alla quantità di incertezza a priori che noi abbiamo sull'esito dell'esperimento;
- Di conseguenza una variabile massimamente informativa è anche una variabile massimamente incerta;
- Si noti che senza incertezza a priori non esiste informazione.

Esempio #1: Lancio di una moneta

- Si consideri una moneta, in cui la croce (C) esce con probabilità $\mathbb{P}(\{C\}) = p$, e la testa (T) con probabilità $\mathbb{P}(\{T\}) = 1 - \mathbb{P}(\{C\}) = 1 - p$;
- Da $\Omega = \{\{C\}, \{T\}\}$ formiamo la σ -algebra $\mathcal{T} = \mathcal{P}(\Omega) = \{\emptyset, \{C\}, \{T\}, \Omega\}$;
- Denotato $\mathcal{E}$ questo esperimento aleatorio, vremo quindi:

$$\begin{aligned} H(\mathcal{E}) &= p \log \frac{1}{p} + (1 - p) \log \frac{1}{1-p} = \\ &= -p \log p - (1 - p) \log(1 - p) = H(p, 1 - p) = H_2(p) = H(p) \end{aligned}$$

- Si noti il leggero abuso notazionale che la precedente equazione ha adottato;
- Si noti anche che anche per una sorgente binaria che emetta 0 con probabilità p e 1 con probabilità $(1 - p)$ avremo la stessa espressione;
- In generale l'entropia di ogni esperimento con esito binario ammette l'espressione precedente.


Esempio #2: parità del lancio di un dado

- Si consideri il lancio di un dado i cui 6 possibili risultati abbiano probabilità $\{u_i\}_{i=1}^6$, dove ovviamente $\sum_i u_i = 1$;
- Vogliamo misurare l'incertezza sulla parità del lancio, cioè sull'esperimento i cui eventi di interesse sono $\text{Pari} = \{2, 4, 6\}$, $\text{Dispari} = \{1, 3, 5\}$.
- Naturalmente, abbiamo $\Omega = \{\text{Even}, \text{Odd}\}$, $\mathcal{T} = \{\emptyset, \text{Pari}, \text{Dispari}, \Omega\}$;
- Valutando l'entropia, avremo:

$$\begin{aligned}
 H(\mathcal{E}) &= \mathbb{P}(\text{Pari}) \log \frac{1}{\mathbb{P}(\text{Pari})} + \mathbb{P}(\text{Dispari}) \log \frac{1}{\mathbb{P}(\text{Dispari})} = \\
 &= \overbrace{(u_2 + u_4 + u_6)}^p \log \frac{1}{(u_2 + u_4 + u_6)} + \overbrace{(u_1 + u_3 + u_5)}^{1-p} \log \frac{1}{(u_1 + u_3 + u_5)} = \\
 &= p \log \frac{1}{p} + (1-p) \log \frac{1}{1-p} = H_2(p, 1-p) = H_2(p) = H(p)
 \end{aligned}$$

Comportamento di $H(p) = H_2(p, 1 - p)$

- Una conseguenza fondamentale - Una variabile aleatoria binaria (cioè, u binary digit, o binit) che assuma valore 1 con probabilità p trasporta **al più** un bit di informazione.
- Un binit corrisponde a 1 bit se e solo se $p = \frac{1}{2}$. Questa è la chiave della compressione dati



Un teorema utile: Disuguaglianza di Jensen

- Dalle precedenti relazioni, si vede che l'entropia di una variabile aleatoria è espressa nella seguente forma generale:

$$H(X) = \mathbb{E}[i(X)] = \mathbb{E}[g(X)] , \quad \text{con } g(\cdot) = \log \left[\frac{1}{p_X(\cdot)} \right]$$

- Problema:** Esiste una relazione generale che leghi (anche sotto forma di disuguaglianza) le quantità

$$\mathbb{E}[g(X)] \quad \text{e} \quad g(\mathbb{E}[X]) ?$$


- Risposta:** No, a meno che $g(\cdot)$ ammetta concavità costante su tutto l'intervallo reale $[x_{\text{MIN}}, x_{\text{MAX}}]$, dove x_{MIN} è il più piccolo valore di $\mathcal{X}$ e x_{MAX} il più grande.

Funzioni convesse e differenziabili

- Si consideri dapprima una funzione $g(x)$ convessa e due volte differenziabile;
- Questo significa che $g(\cdot)$ è sempre al di sopra di una sua tangente in un qualunque punto (vedi figura);
- Matematicamente, questo corrisponde alla condizione:

$$g(\lambda x_0 + (1 - \lambda)x_1) \leq \lambda g(x_0) + (1 - \lambda)g(x_1), \quad \lambda \in [0, 1]$$

- Una funzione concava è sempre **al di sotto** della sua tangente in un qualunque punto e la condizione vale con $\geq$.



Disuguaglianza di Jensen

- Sia $g(x)$ convessa e differenziabile nell'intervallo $\mathcal{I} \supseteq \mathcal{X}$;
- Sia $X \in \mathcal{X}$ una variabile aleatoria arbitraria. Allora:

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}[X])$$

- Simmetricamente, se $g(x)$ è concava e differenziabile sull'intervallo $\mathcal{I} \supseteq \mathcal{X}$, allora:

$$\mathbb{E}[g(X)] \leq g(\mathbb{E}[X])$$

- L'uguaglianza vale o se $g(\cdot)$ è lineare o se X non è aleatoria (cioè, costante con $\omega \in \Omega$).
- Se $g(x)$ non ammette concavità costante su $\mathcal{I}$ non esiste una relazione generale.

Dimostrazione per funzioni convesse differenziabili

- Sia $\mu_X = \mathbb{E}[X]$: questa è una combinazione convessa di valori di $\mathcal{X}$, per cui appartiene necessariamente ad un intervallo reale $\mathcal{I} \supseteq \mathcal{X}$.
- La tangente a $g(x)$ in μ_X ha equazione:

$$h(x) = g'(\mu_X)(x - \mu_X) + g(\mu_X)$$

- Per la convessità di $g(x)$, $x \in \mathcal{X}$ avremo:

$$g(X) \geq g'(\mu_X)(X - \mu_X) + g(\mu_X)$$

- Prendendo la media ad entrambi i membri avremo:

$$\mathbb{E}[g(X)] \geq g'(\mu_X)\mathbb{E}[(X - \mu_X)] + g(\mu_X) = g(\mathbb{E}[X])$$

Commenti

- Il teorema si estende a funzioni "convesse" non differenziabili (per esempio, funzioni con punti angolosi quali $|x|$) ricorrendo al concetto di super-derivata;
- La dimostrazione per il caso di funzioni concave viene lasciata come esercizio. Si ricordi che se $g(x)$ è concava per $x \in \mathcal{I} \supseteq \mathcal{X}$, allora:

$$g(\lambda x_0 + (1 - \lambda)x_1) \geq \lambda g(x_0) + (1 - \lambda)g(x_1), \quad \lambda \in [0, 1]$$

- Pertanto una funzione differenziabile concava soddisfa la relazione:

$$g(x) \leq g'(x_0)(x - x_0) + g(x_1)$$

- Come per il caso convesso, anche qui la relazione è applicabile a funzioni concave non differenziabili.

Esempi di applicazione: proprietà dell'entropia

- Abbiamo visto che

$$H(X) = \mathbb{E} \left[\log \frac{1}{p_X[X(\omega)]} \right] = \mathbb{E} \left[\log \frac{1}{Y(\omega)} \right]$$

con

$$Y(\omega) = \frac{1}{p_X[X(\omega)]} \implies \mathbb{E}[Y(\omega)] = \sum_{x \in \mathcal{X}} \frac{1}{p_X(x)} p_X(x) = |\mathcal{X}|$$

- Si ricordi che $\frac{d^2 \log y}{dy^2} = -\frac{1}{y^2} < 0$, per cui $\log(y)$ è concava $\forall y > 0$;
- Pertanto dalla disuguaglianza di Jensen consegue

$$H(X) = \mathbb{E} \left[\log \frac{1}{Y(\omega)} \right] \leq \log(\mathbb{E}[Y(\omega)]) = \log |\mathcal{X}|$$

- **Conseguenza:** Tra tutte le pmf su $\mathcal{X}$ quella che corrisponde a massima entropia è l'uniforme, cioè

$$p_X(x) = \frac{1}{|\mathcal{X}|} \implies H(X) = \log |\mathcal{X}|$$

Divergenza tra leggi di probabilità

- Si consideri un alfabeto discreto $\mathcal{X}$;
- Siano $p_1(x)$ e $p_2(x)$ due pmf definite su questo alfabeto;
- Si definisce entropia relativa (o divergenza, o distanza di Kullback-Leibler, KL) tra $p_1(\cdot)$ e $p_2(\cdot)$ la quantità:

$$D_{1,2} = D(p_1(x) \parallel p_2(x)) = \sum_{x \in \mathcal{X}} p_1(x) \log \left[\frac{p_1(x)}{p_2(x)} \right] = \mathbb{E}_1 \left[\log \frac{p_1(X)}{p_2(X)} \right]$$

dove $\mathbb{E}_1[\cdot]$ denota media statistica eseguita assumendo che la distribuzione sia $p_1(x)$.

- Analogamente, potremo definire

$$D_{2,1} = D(p_2(x) \parallel p_1(x)) = \sum_{x \in \mathcal{X}} p_2(x) \log \left[\frac{p_2(x)}{p_1(x)} \right] = \mathbb{E}_2 \left[\log \frac{p_2(X)}{p_1(X)} \right]$$

- Si noti che $D_{1,2} \neq D_{2,1}$, per cui né $D_{1,2}$ né $D_{2,1}$ sono delle distanze.

Caratteristiche della Divergenza

- Siano $p(x)$ e $q(x)$ due leggi di probabilità definite su $\mathcal{X}$;
- La divergenza è non negativa. Infatti:

$$\begin{aligned} -D(p \parallel q) &= \mathbb{E}_p \left[\log \frac{q(X)}{p(X)} \right] \leq \log \mathbb{E}_p \left[\log \frac{q(X)}{p(X)} \right] \\ &= \log \sum_{x \in \mathcal{X}} \frac{q(x)}{p(x)} p(x) = \log \sum_{x \in \mathcal{X}} q(x) = \log 1 = 0 \end{aligned}$$

dove la prima disuguaglianza deriva dalla disuguaglianza di Jensen.

- Inoltre, poiché il segno $=$ vale solo se $q(x) = p(x)$, la divergenza tra due pmf è nulla se e solo se le due leggi sono uguali.
- La divergenza è convessa, nel senso che:

$$D(\alpha p_1 + (1 - \alpha)q_1 \parallel \alpha p_2 + (1 - \alpha)q_2) \leq \alpha D(p_1 \parallel q_1) + (1 - \alpha)D(p_2 \parallel q_2)$$

Sorgenti di informazione

- Una sorgente di informazione è schematizzabile come un "blocco" che in ogni istante n emette una lettera presa da un alfabeto $\mathcal{X}$, detto alfabeto di sorgente;
- Una sorgente discreta senza memoria (Discrete Memoryless Source, DMS) è modellabile come un blocco che emetta una sequenza di lettere senza conservare memoria delle emissioni precedenti. Pertanto una generica emissione è rappresentata dalla stringa aleatoria

$$\dots, X_1, X_1, \dots, X_n, \dots$$

dove le X_i sono variabili aleatorie con una pmf comune (sorgente stazionaria), sia essa $p_X(x)$, $x \in \mathcal{X}$.

- Si definisce **codifica di sorgente** la rappresentazione delle emissioni della sorgente con stringhe binarie quanto più brevi possibili (si vedano slide seguenti).

Un esempio dell'utilità della probabilità : Codifica di Sorgente

- Torniamo all'esempio precedente (slide 4): la differenza tra i due codici è che uno è a lunghezza **fissa**, l'altro a lunghezza **variabile**;
- Noi comunque vogliamo codificare stringhe di lettere dell'alfabeto di sorgente;
- Siccome di un codice a lunghezza variabile non sappiamo la lunghezza di ogni codeword, abbiamo due possibilità:
 - 1 Poniamo un segno di interpunzione tra due codewords successive: questo darebbe luogo ad uno "spreco" ed ad un allungamento del numero medio di bit per lettera di sorgente;
 - 2 Imponiamo che "concatenazioni" di codewords corrispondano in modo biunivoco a concatenazioni di lettere dell'alfabeto di sorgente.

Formalizzazione: la codifica di sorgente

- Sia $\{X_n\}_{n=\dots,-1,0,\dots}$ una sequenza di lettere di una sorgente arbitraria, con $X_n \in \mathcal{X}$, $|\mathcal{X}| = M$;
- Vogliamo rappresentare ogni lettera mediante una stringa binaria, cioè istituire la corrispondenza:

$$C : x \in \mathcal{X} \longrightarrow C(x) = \{0, 1\}^{\ell(x)}$$

- Vogliamo inoltre che una qualunque concatenazione di codewords corrisponda biunivocamente ad un'unica concatenazione di lettere: questa si chiama condizione di **univoca decifrabilità**.
- Un codice di sorgente si dice univocamente decifrabile se, $\forall n$, valgono le condizioni:

$$C : \mathbf{x}^n \in \mathcal{X}^n \longrightarrow C(\mathbf{x}^n) = C(x_1)C(x_2)\cdots C(x_n) \in \{0, 1\}^{\sum_{i=1}^n \ell(x_i)}$$


$$\mathbf{x}^n = (x_1, \dots, x_n) = C^{-1}[C(\mathbf{x}^n)] = (C^{-1}[C(x_1)], \dots, C^{-1}[C(x_n)]) \in \mathcal{X}^n$$

Codici istantanei


- Un codice si dice istantaneo se ogni parola codice può essere decodificata appena si presenta nella stringa binaria;
- I codici istantanei sono per definizione quelli per cui nessuna parola codice può essere **prefisso** di un'altra parola codice.
- Ogni codice binario può essere rappresentato su un albero binario di profondità $\max[\ell(x)] = \ell_{\text{MAX}}$.
- Esempio - Si considerino i tre codici

x	$p_X(x)$	$C_1(x)$	$C_2(x)$	$C_3(x)$
1	$\frac{1}{4}$	000	0	10
2	$\frac{3}{32}$	001	1001	110
3	$\frac{1}{8}$	010	100	001
4	$\frac{1}{32}$	011	1111	1111
5	$\frac{3}{16}$	100	01	000
6	$\frac{1}{8}$	101	110	010
7	$\frac{1}{16}$	110	1100	1110
8	$\frac{1}{8}$	111	111	011


Rappresentazione ad albero dei codici



$C_1(x), \ell_{\text{MAX}} = 3$



$C_2(x), \ell_{\text{MAX}} = 4$



$C_3(x), \ell_{\text{MAX}} = 4$

Qualche commento

- $C_1(x)$ è univocamente decifrabile (in quanto a lunghezza fissa);
- $C_2(x)$ e $C_3(x)$ sono a lunghezza variabile. Dal momento che $\ell = \ell(X)$ la lunghezza media dei due codici è:

$$L_2 = \mathbb{E}[\ell_2(X)] = 2.5 \text{ [bits/symbol]} \quad L_3 = \mathbb{E}[\ell_3(X)] = 2.84375 \text{ [bits/symbol]}$$

- Si noti che entrambi hanno lunghezza media < 3 , ma solo $C_3(x)$ è univocamente decifrabile. Infatti, adottando $C_2(x)$, la stringa binaria 1111000 corrisponde alla sequenza $(x_1, x_2, x_3) = (8, 3, 1)$, ma anche alla sequenza $(x_1, x_2, x_3, x_4) = (4, 1, 1, 1)$.
- Quindi siamo interessati a minimizzare $\mathbb{E}[\ell(X)]$ che a preservare l'univoca decifrabilità.
- Si noti che $C_3(x)$ è un codice a prefisso, in quanto nessuna parola codice è prefisso di un'altra: questo si vede perché tutte le parole codice si trovano su **nodì terminali**.

Codici a prefisso

- Come visto, condizione necessaria perchè un codice sia a prefisso è che, nella sua rappresentazione ad albero, ogni parola codice sia su un nodo terminale.
- Il numero massimo di nodi terminali di un albero binario di profondità ℓ_{MAX} è $2^{\ell_{\text{MAX}}}$.
- Siccome rendere terminale un nodo di profondità $\ell(x)$ elimina $2^{\ell_{\text{MAX}} - \ell(x)}$ nodi di profondità ℓ_{MAX} , una condizione necessaria perchè un insieme di lunghezze $\{\ell(x)\}_{x \in \mathcal{X}}$ sia compatibile con la condizione del prefisso è la **disuguaglianza di Kraft**

$$\sum_{x \in \mathcal{X}} 2^{\ell_{\text{MAX}} - \ell(x)} \leq 2^{\ell_{\text{MAX}}} \implies \sum_{x \in \mathcal{X}} 2^{-\ell(x)} \leq 1$$

- Si può dimostrare che la condizione è anche sufficiente. D'ora in poi ci focalizzeremo sui soli codici a prefisso (o istantanei).

Codice di Shannon

- Si assuma di avere una sorgente con alfabeto M -ario, $X \in \{x_1, \dots, x_M\}$.
- Si assuma che la legge di probabilità con cui le lettere vengono emesse sia nota, cioè assumiamo di conoscere $\{p_X(x_i) = \Pr\{X = x_i\}\}_{i=1}^M$;
- Si definisce codice di Shannon quello che utilizza per x_i una stringa binaria di lunghezza

$$\ell(x_i) = \left\lceil \log \frac{1}{p_X(x_i)} \right\rceil$$

- Si noti che

$$\begin{aligned} \log \frac{1}{p_X(x_i)} \leq \ell(x_i) \leq \log \frac{1}{p_X(x_i)} + 1 \\ \sum_{i=1}^M 2^{-\ell(x_i)} \leq \sum_{i=1}^M 2^{-\log \frac{1}{p_X(x_i)}} \leq \sum_{i=1}^M p_X(x_i) = 1 \end{aligned}$$

- Pertanto esiste almeno un codice istantaneo che abbia le lunghezze del codice di Shannon.

Entropia e comprimibilità

- Torniamo al codice di Shannon. Abbiamo visto che la condizione

$$\log \frac{1}{p_X(x_i)} \leq \ell(x_i) < \log \frac{1}{p_X(x_i)} + 1$$

dà luogo all'esistenza di codici a prefisso;

- Dalla precedente relazione abbiamo:

$$\underbrace{\sum_{i=1}^M p_X(x_i) \log \frac{1}{p_X(x_i)}}_{H(X)} \leq \underbrace{\sum_{i=1}^M p_X(x_i) \ell(x_i)}_L < H(X) + 1$$


- Questa relazione predice che $L \geq H(X)$, per cui l'entropia di una sorgente dà una misura della sua comprimibilità;
- La condizione precedente è anche una condizione necessaria per l'univoca decifrabilità.

Codici a prefisso ottimi: codici di Huffman

- Disporre verticalmente i simboli in ordine di probabilità decrescente;
- Raggruppa i due simboli meno probabili in un "macrosimbolo" cui si assegna la somma delle probabilità dei due simboli che lo compongono: questo riduce di un'unità la cardinalità dell'alfabeto;
- Ripetere il passo precedente fino a quando non si arriva alla radice dell'albero, cioè ad un unico macrosimbolo con probabilità 1;
- Si assegna 1/0 ai rami ascendenti/discendenti dell'albero: la parola codice di ogni nodo terminale è la sequenza dei bit necessari per arrivare dalla radice al nodo su cui essa è posta.
- **Esempio:** Si consideri un alfabeto con 8 simboli, $\mathcal{X} = \{1, 2, 3, 4, 5, 6, 7, 8\}$ e le due pmf riportate di seguito:


$$p_1(x) = \left\{ \frac{1}{4}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16} \right\} \quad p_2(x) = \left\{ \frac{1}{3}, \frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{27}, \frac{2}{27}, \frac{1}{6}, \frac{1}{18} \right\}$$

Codice di Huffman per $p_1(x)$



$$L = \mathbb{E}[\ell(X)] = 2.75 \text{ [bits/symbol]} \quad H(X) = 2.75 \text{ [bits]}$$

Codice di Huffman per $p_2(x)$



$$L = \mathbb{E}[\ell(X)] = 2.759 \text{ [bits/symbol]} \quad H(X) = 2.7017 \text{ [bits]}$$

Commenti

- Il codice di Huffman non è unico: per esempio nelle costruzioni precedenti avremmo potuto unire i simboli meno probabili diversamente;
- Si noti che in entrambi i casi le due lettere meno probabili differiscono solo nell'ultimo bit: questa è una caratteristica di tutti i codici di Huffman;
- BEntrambi i codici sono ottimi, nel senso che raggiungono la minima lunghezza media. Tuttavia, solo il codice di Huffman corrispondente a $p_1(\cdot)$ raggiunge una lunghezza media pari all'entropia della sorgente;
- Questo suggerisce che se il limite entropico è raggiungibile, allora questo lo è necessariamente da un codice di Huffman. Se, viceversa, il codice di Huffman non raggiunge il limite entropico, questo significa che tale limite non è ottenibile.
- Si può dimostrare che il limite entropico è raggiungibile se e solo se

$$p_X(x) \propto 2^{-\ell(x)}$$

Esercizio: dimostrazione della precedente proprietà

- Consideriamo la seguente catena di relazioni:

$$\begin{aligned} L - H &= \mathbb{E}[\ell(X)] - H(X) = \sum_{x \in \mathcal{X}} \left[\ell(x) - \log \frac{1}{p_X(x)} \right] p_X(x) = \\ &= \sum_{x \in \mathcal{X}} \left[\log 2^{\ell(x)} - \log \frac{1}{p_X(x)} \right] p_X(x) = \sum_{x \in \mathcal{X}} \left[\log \frac{p_X(x)}{2^{-\ell(x)}} \right] p_X(x) \end{aligned}$$

- Si definisca la pmf $r(x) = \frac{2^{-\ell(x)}}{c}$, con $c = \sum_{y \in \mathcal{X}} 2^{-\ell(y)}$;
- Abbiamo

$$L - H = \sum_{x \in \mathcal{X}} \left[\log \frac{p_X(x)c}{2^{-\ell(x)}} \right] p_X(x) + \log \frac{1}{c} = D(p_X \parallel r(x)) + \log \frac{1}{c}$$

- Si noti che $c \leq 1$ (disuguaglianza di Kraft), per cui $\log \frac{1}{c} \geq 0$, cioè $L = H$ se e solo se $p_X(x) = r(x) \propto 2^{-\ell(x)}$ e $c = 0$, cioè $\sum 2^{-\ell(x)} = 1$.

Coppie di variabili aleatorie

- Siano $X, Y \in \mathcal{X} \times \mathcal{Y}$ una coppia di variabili aleatorie discrete con pmf congiunta $p_{X,Y}(x, y)$;
- **Domanda:** Quale è l'incertezza media rimossa (o l'informazione media acquisita) quando se ne leggono i valori?
- **Immediata generalizzazione** del concetto di entropia:

$$H(X, Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log \frac{1}{p_{X,Y}(x, y)} = \mathbb{E} \left[\log \frac{1}{p_{X,Y}(X, Y)} \right]$$

- Si noti che, se le due variabili aleatorie sono indipendenti (e solo in questo caso), allora $p_{X,Y}(x, y) = p_X(x)p_Y(y)$, per cui

$$H(X, Y) = \mathbb{E} \left[\log \frac{1}{p_X(X)} \right] + \mathbb{E} \left[\log \frac{1}{p_Y(Y)} \right] = H(X) + H(Y)$$

Esempio

Si considerino le seguenti due leggi congiunte definite su $\{0,1\} \times \{0,1\}$.

(x, y)	$p_{X,Y}(x, y)$
(0,0)	$\frac{1}{9}$
(0,1)	$\frac{2}{9}$
(1,0)	$\frac{2}{9}$
(1,1)	$\frac{4}{9}$

(x, y)	$q_{X,Y}(x, y)$
(0,0)	0
(0,1)	$\frac{1}{4}$
(1,0)	$\frac{1}{8}$
(1,1)	$\frac{5}{8}$

Si vogliono calcolare $H_p(X, Y)$, $H_p(X)$, $H_p(Y)$ e $H_q(X, Y)$, $H_q(X)$, $H_q(Y)$.

- $p_{X,Y}(x, y)$ è chiaramente una legge congiunta di variabili indipendenti;
- $q_{X,Y}(x, y)$ è altrettanto chiaramente una legge congiunta di variabili dipendenti;
- Perché?

Esempio (continuazione)

- Marginalizzando le congiunte troviamo le pmf di X e Y secondo le due leggi:

$$p_X(0) = p_{X,Y}(0,0) + p_{X,Y}(0,1) = \frac{1}{3} \quad p_X(1) = \frac{2}{3}$$

$$p_Y(0) = p_{X,Y}(0,0) + p_{X,Y}(1,0) = \frac{1}{3} \quad p_Y(1) = \frac{2}{3}$$

$$q_X(0) = q_{X,Y}(0,0) + q_{X,Y}(0,1) = \frac{1}{4} \quad q_X(1) = \frac{3}{4}$$

$$q_Y(0) = q_{X,Y}(0,0) + q_{X,Y}(1,0) = \frac{1}{8} \quad q_Y(1) = \frac{7}{8}$$

- Dal confronto con la tabella si vede chiaramente che $p_{X,Y}(x,y) = p_X(x)p_Y(y)$, mentre $q_{X,Y}(x,y) \neq q_X(x)q_Y(y)$.

Esempio (continuazione)

- Siccome avremo $H_p(X) = H\left(\frac{1}{3}, \frac{2}{3}\right) = H_p(Y) = 0.9183$, otterremo, per la legge $p_{X,Y}(x, y)$, $H_p(X, Y) = 1.8366$ bit.
- Passando alla legge $q_{X,Y}(x, y)$, abbiamo:

$$H_q(X) = H\left(\frac{1}{4}, \frac{3}{4}\right) = 0.8113 \quad H_q(Y) = H\left(\frac{1}{8}, \frac{7}{8}\right) = 0.5436$$

- Applicando la definizione avremo:

$$H_q(X, Y) = \frac{1}{4} \log 4 + \frac{1}{8} \log 8 + \frac{5}{8} \log \frac{8}{5} = 1.2988 \simeq 1.3 \text{ bit}$$

- Poiché $H_q(X) + H_q(Y) = 1.3549$ bit, $H_q(X, Y) < H_q(X) + H_q(Y)$.

Come mai?

Entropia congiunta ed entropia condizionale

- Dalla legge della probabilità composta sappiamo che

$$p_{X,Y}(x,y) = p_{X|Y}(x|y)p_Y(y) = p_{Y|X}(y|x)p_X(x)$$

- Sostituendo nell'espressione dell'entropia congiunta avremo la **regola della catena**:

$$H(X,Y) = \mathbb{E} \left[\log \frac{1}{p_X(X)} \right] + \mathbb{E} \left[\log \frac{1}{p_{Y|X}(Y|X)} \right] = H(X) + H(Y|X)$$

- La quantità $H(Y|X)$ prende il nome di **entropia condizionale**:

$$H(Y|X) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x,y) \log \frac{1}{p_{Y|X}(y|x)}$$

- Si noti che

$$H(X,Y) = H(X) + H(X|Y) = H(Y) + H(X|Y)$$

Interpretazione dell'entropia condizionale

- Si noti che l'incertezza media a priori su una variabile aleatoria X è $H(X)$;
- Si supponga ora che si conoscano le realizzazioni di un'altra variabile aleatoria Y , da cui X ha un certo grado di predicibilità dettato dalla legge congiunta $p_{X,Y}(x,y)$;
- L'entropia condizionale $H(X|Y)$ rappresenta quindi l'incertezza residua su X una volta noto Y , e "quantifica" la quantità di informazione su X che non può essere estratta da Y .
- Sulla base di questa interpretazione, si può intuire che l'entropia condizionale soddisfa:

$$0 \leq H(X|Y) \leq H(X)$$

dove $H(X|Y) = 0$ implica che Y e X sono funzionalmente dipendenti mediante una trasformazione deterministica e $H(X|Y) = H(X)$ implica statistica indipendenza tra X e Y .

Mutua Informazione tra variabili aleatorie

- Date due variabili aleatorie $(X, Y) \sim p_{X,Y}(x, y)$ sappiamo dalla regola della catena che

$$H(X) - H(X|Y) = H(Y) - H(Y|X)$$

- La quantità $I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$ si chiama **mutua informazione** tra X e Y e misura il grado di dipendenza statistica (e quindi di predicibilità) tra le due variabili aleatorie.
- Si noti che

$$I(X; Y) = \mathbb{E} \left[\frac{1}{p_X(X)} \right] - \mathbb{E} \left[\frac{1}{p_{X|Y}(X|Y)} \right] = \mathbb{E} \left[\frac{p_{X,Y}(X, Y)}{p_X(X)p_Y(Y)} \right]$$

- Pertanto:

$$I(X; Y) = D(p_{X,Y}(x, y) \parallel p_X(x)p_Y(y))$$

Alcune conseguenze

- Si ricordi che, se $p(\cdot)$ e $q(\cdot)$ sono due leggi di probabilità, allora:

$$D(p \parallel q) \geq 0 \quad D(p \parallel q) = 0 \iff p = q$$

- Questo implica che.

$$I(X; Y) \geq 0 \implies H(X) \geq H(X|Y) \quad H(Y) \geq H(Y|X)$$

cioè il condizionamento non aumenta l'entropia;


- Inoltre:

$$I(X; Y) = 0 \iff p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

cioè la mutua informazione tra due variabili aleatorie è nulla se e solo se sono indipendenti.

- Ovviamente, se due variabili aleatorie sono indipendenti allora $H(X|Y) = H(X)$ e $H(Y|X) = H(Y)$.

Diagramma di Venn delle principali grandezze



Definizione di sorgente

- Una generica sorgente di informazione è rappresentabile mediante lo schema di figura



- La sequenza $\{X_i\}_{i \in \mathbb{Z}}$ è un **processo aleatorio tempo-discreto** che in generale può essere arbitrario;
- Nell'ambito del presente corso, assumeremo che il processo sia:
 - † Ampiezza-discreto con alfabeto $\mathcal{X}$ a cardinalità finita;
 - † Stazionario di ordine qualsiasi;
 - † Completamente caratterizzato, nel senso che le pmf congiunte di ordine qualsiasi siano a priori note.
- La sorgente si dice **senza memoria** se il processo $\{X_i\}$ è indipendente: per sorgenti discrete senza memoria si utilizza l'**acronimo DMS, Discrete Memory-less Source**.

Contenuto informativo di una DMS

- Si consideri una DMS, e se ne prenda un **blocco finito di simboli**, $\mathbf{X}_n = (X_1, \dots, X_n) \in \mathcal{X}^n$;
- La quantità di informazione media trasportata da questo blocco è, con ovvia generalizzazione degli argomenti precedenti:

$$H(\mathbf{X}^n) = H(X_1, \dots, X_n) = \sum_{\mathbf{x}^n \in \mathcal{X}^n} p_{\mathbf{X}^n}(\mathbf{x}^n) \log \left[\frac{1}{p_{\mathbf{X}^n}(\mathbf{x}^n)} \right]$$

- D'altra parte, per l'indipendenza della sorgente avremo $p_{\mathbf{X}^n}(\mathbf{x}^n) = \prod_i p_{X_i}(x_i)$, e $H(\mathbf{X}^n) = \sum H(X_i) = nH(X_1)$.
- Pertanto la quantità media di informazione che ogni simbolo trasporta, definita anche **tasso entropico** della sorgente è:

$$H_\infty(\mathcal{X}) = \lim_{n \rightarrow \infty} \frac{H(\mathbf{X}^n)}{n} = H(X_1)$$

- In altre parole, per una DMS il **tasso entropico coincide con l'entropia della singola emissione**.

Sorgenti con memoria

- Rimuoviamo ora l'ipotesi di indipendenza, conservando quella di stazionarietà.
- Ricordiamo la **legge di Bayes**

$$p_{X^n}(x^n) = p_{X_1, \dots, X_n}(x_1, \dots, x_n) = p_{X_1}(x_1)p_{X_2|X_1}(x_2|x_1)p_{X_3|X_2, X_1}(x_3|x_2, x_1) \cdots p_{X_n|X_{n-1}, \dots, X_1}(x_n|x_{n-1}, \dots)$$

- L'entropia congiunta di X^n si scrive dunque

$$H(X^n) = H(X_1) + H(X_2|X_1) + \dots + H(X_n|X_{n-1}, \dots, X_1)$$

- Si noti che la quantità

$$H(X_i|X_{i-1}, \dots, X_1) = \sum_{x^i \in \mathcal{X}^i} p_{X^i}(x^i) \log \left(\frac{1}{p_{X_i|X_{i-1}, \dots, X_1}(x_i|x_{i-1}, \dots, x_1)} \right)$$

rappresenta l'**incertezza residua su X_i una volta che tutti i simboli precedenti siano noti**. In altre parole, questa quantità rappresenta la parte di informazione trasportata da X_i che non è predicibile a partire dai simboli passati, e quindi in ultima analisi l'**innovazione** che X_i trasporta rispetto al passato.

Tasso entropico di sorgenti con memoria

- Ricordiamo che il tasso entropico si può scrivere nella forma

$$H_{\infty}(X) = \lim_{n \rightarrow \infty} \frac{H(\mathbf{X}^n)}{n} = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n H(X_i | X_{i-1}, \dots, X_1)$$

- Il **Teorema di Cesaro** stabilisce che, se $\{b_n\}$ è una successione che ammette limite b , allora:

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n b_i = b \implies H_{\infty}(X) = \lim_{n \rightarrow \infty} H(X_n | X_{n-1}, \dots, X_1)$$

- Dimostrazione. Sia $a_n = \frac{1}{n} \sum_{i=1}^n b_i$. Siccome $b_n \rightarrow b$, avremo:

$$\forall \epsilon > 0 \quad \exists n_0 = n_0(\epsilon) : |b_n - b| < \epsilon \quad \forall n > n_0$$

$$|a_n - b| = \left| \frac{1}{n} \sum_{i=1}^{n_0} a_i + \frac{1}{n} \sum_{i=n_0+1}^n a_i - b \right| \leq \frac{1}{n} \sum_{i=1}^{n_0} |a_i - b| + \frac{1}{n} \sum_{i=n_0+1}^n |a_i - b|$$

$$\sum_{i=1}^{n_0} |a_i - b| \leq \beta \implies |a_n - b| \leq \frac{\beta}{n} + \frac{n - n_0}{n} \epsilon \implies |a_n - b| < \epsilon' \quad n > n'_0$$

Compressione di sorgenti con memoria

- Si consideri una sorgente con memoria, che emetta simboli $\{\dots, X_{-1}, X_0, X_1, \dots\}$;
- Si assuma che la sequenza dei simboli emessi sia un **processo stazionario**, cioè, per ogni k e per ogni h si abbia, per $(i_1, \dots, i_k) \in \{1, \dots, |\mathcal{X}|\}^k$:

$$\mathbb{P}\{X_1 = x_{i_1}, \dots, X_k = x_{i_k}\} = \mathbb{P}\{X_{1+h} = x_{i_1}, \dots, X_{k+h} = x_{i_k}\},$$

- Si supponga che il processo di codifica avvenga considerando blocchi di lunghezza n di simboli;
- Ovviamente, un blocco di simboli di lunghezza n diventa un **macrosimbolo** che varia in un alfabeto $\mathcal{X}^n$ di cardinalità $|\mathcal{X}|^n$;
- In altre parole, ci riduciamo ad una condizione in cui occorra codificare un singolo macrosimbolo.

Limiti di comprimibilità di sorgenti con memoria

- La codifica non può che essere univocamente decifrabile, per cui deve soddisfare la disuguaglianza di Kraft;
- Sappiamo dalle precedenti derivazioni che una variabile aleatoria $Y \in \mathcal{Y}$ è codificabile **senza perdite** con un codice istantaneo a lunghezza media:

$$H(Y) \leq L < H(Y) + 1$$

- Applicando la precedente relazione al vettore aleatorio $\mathbf{X}_n = (X_1, \dots, X_n)$ avremo

$$H(\mathbf{X}^n) \leq L < H(\mathbf{X}^n) + 1$$

- Pertanto, il numero medio di bit per simbolo, $\frac{L}{n}$ soddisfa la relazione

$$\frac{H(\mathbf{X}^n)}{n} \leq L_n < \frac{H(\mathbf{X}^n)}{n} + \frac{1}{n} \Rightarrow_{n \rightarrow \infty} H_\infty(X) \leq L_n < H_\infty(X) + \epsilon$$

Alcune conseguenze

- Dalla relazione precedente, si nota come **mediante codifica a blocchi** si può arrivare ad utilizzare un numero medio di bit per simbolo vicino quanto vogliamo al tasso entropico, purchè la lunghezza del blocco sia sufficientemente grande;
- Si noti che per sorgenti senza memoria il limite di comprimibilità si semplifica:

$$H(\mathbf{X}^n) = nH(X_1) \implies H(X) \leq L_n < H(X) + \epsilon$$

- Ricordando inoltre che

$$\lim_{n \rightarrow \infty} \frac{H(\mathbf{X}^n)}{n} = \lim_{n \rightarrow \infty} H(X_n | X_{n-1}, \dots, X_1)$$

e che **il condizionamento non aumenta (ma anzi, in genere, diminuisce) l'entropia**, abbiamo che le sorgenti con memoria possono godere di limiti di comprimibilità molto più significativi delle sorgenti senza memoria.

- Nel seguito, illustreremo questo concetto con un esempio.

Un esempio: Sorgenti Markoviane

- Sia $X(n) \in \mathcal{X}$ una sequenza aleatoria su un alfabeto discreto $\mathcal{X}$ di cardinalità M ;
- $X(n)$ è una catena di Markov se :

$$f_{X(n)|X(n-1),\dots,X(1)}(x_n|x_{n-1},\dots) = f_{X(n)|X(n-1)}(x_n|x_{n-1})$$

cioè se, dato $X(n-1)$, $X(n)$ è condizionalmente indipendente da tutti gli elementi che precedono $X(n-1)$.

- D'ora in poi assumiamo che sia $\mathcal{X} = \{1, \dots, M\}$ per semplicità notazionale. Definiamo *matrice di transizione* della catena markoviana la matrice $M \times M$:

$$P = \begin{bmatrix} f_{X(n)|X(n-1)}(1|1) & f_{X(n)|X(n-1)}(2|1) & \dots & f_{X(n)|X(n-1)}(M|1) \\ f_{X(n)|X(n-1)}(1|2) & f_{X(n)|X(n-1)}(2|2) & \dots & f_{X(n)|X(n-1)}(M|2) \\ \dots & \dots & \dots & \dots \\ f_{X(n)|X(n-1)}(1|M) & f_{X(n)|X(n-1)}(2|M) & \dots & f_{X(n)|X(n-1)}(M|M) \end{bmatrix}$$

- Questa matrice può in generale essere tempo-variante. Qui noi assumiamo che essa sia tempo-invariante, cioè che la catena sia *omogenea*.

Diagramma di stato di una catena di Markov

- La catena può essere rappresentata come in figura 1: i nodi rappresentano gli stati ammissibili, mentre gli archi che connettono due vertici sono etichettati mediante gli elementi corrispondenti della matrice di transizione P .
- La rappresentazione si applica a catene non omogenee, nel qual caso le etichette sono tempo-varianti;
- La catena si definisce **indecomponibile** se ogni nodo può essere raggiunto da ogni altro nodo in un numero finito di passi.




Figura 1: Rappresentazione della catena mediante diagramma di stato

Caratterizzazione di catene omogenee

- Una catena è completamente caratterizzata dalla conoscenza di $\mathbf{P}$ and e della pmf marginale in ogni istante. Infatti:

$$f_{X(n)}(i) = \sum_{j=1}^M f_{X(n)|X(n-1)}(i|j) f_{X(n-1)}(j) \implies \mathbf{f}(n) = \mathbf{P}^T \mathbf{f}(n-1)$$

con $\mathbf{f}(n) = [f_{X(n)}(1), \dots, f_{X(n)}(M)]^T$, i.e. $\mathbf{f}(n) = (\mathbf{P}^T)^i \mathbf{f}(n-i)$.

- Inoltre, se $\mathbf{x}_{n-\ell+1:n} = (i_{n-\ell+1}, i_{n-\ell+2}, \dots, i_n) \in \{1, \dots, M\}^\ell$:

$$f_{\mathbf{X}_{n-\ell+1:n}}(\mathbf{x}_{n-\ell+1:n}) = \prod_{k=0}^{\ell-1} f_{X(n-k)|\mathbf{X}_{n-\ell+1:n-k}}(x_{n-k}|\mathbf{x}_{n-\ell+1:n-k-1}) =$$

$$\begin{aligned} & \prod_{k=0}^{\ell-1} f_{X(n-k)|X(n-k-1)}(i_{n-k}|i_{n-k-1}) = \\ & = f_{X(n-\ell+1)}(i_{n-\ell+1}) \prod_{k=0}^{\ell-2} f_{X(n-k)|X(n-k-1)}(i_{n-k}|i_{n-k-1}) \end{aligned}$$

Stationary Distribution of a MC

- Assume that the chain starts at time n_0 , with a marginal $\mathbf{f}(n_0)$. Of course, since $\mathbf{f}(n_0 + n) = (\mathbf{P}^T)^n \mathbf{f}(n_0)$ the chain is *not* stationary.
- Question: can the initial condition be forgotten, so that the chain stationarizes?
- This requires that, for sufficiently large n , $\mathbf{f}(n)$ be independent of n , i.e.:

$$\mathbf{f}(n+1) = \mathbf{f}(n) \implies \mathbf{P}^T \mathbf{f} = \mathbf{f}$$

- Otherwise stated, if a stationary distribution exists, this is necessarily equal to the eigenvector corresponding to the unit eigenvalue of $\mathbf{P}^T$.
- What does this mean?

On the eigendecomposition of P^T

- This discussion is limited to undecomposable chains;
- Notice preliminarily that all of the columns of P^T sum up to one;
- As a consequence, denoting by I_M the order- M identity matrix, the equation

$$|\lambda I_M - P^T| = 0$$

always admits $\lambda = 1$ as a solution, since all the columns of $I_M - P^T$ sum up to zero.

- As a consequence, a stationary distribution exists if and only if the elements of the unit eigenvector of P^T have all the same sign (in which case the eigenvector can be normalized to be a probability law).

Limiting distribution of an MC

- The matrix $\mathbf{P}^T$ is also called a left-stochastic matrix (because columns sum up to one);
- The k -th power of a left-stochastic matrix is itself left-stochastic;
- No eigenvalue of a stochastic matrix can have a modulus which exceeds one (Perrius-Frobenius theorem);
- Since the eigenvalues of $(\mathbf{P}^T)^k$ are $\{\lambda_i^k\}$, with λ_i the eigenvalues of $\mathbf{P}^T$, $(\mathbf{P}^T)^k$ becomes rank-1, i.e.:

$$(\mathbf{P}^T)^k \rightarrow \gamma \mathbf{u} \mathbf{u}^T$$

with $\mathbf{u}$ parallel to the unit eigenvector. As a consequence, in $\mathbf{f}(n) \propto \mathbf{u}$ (i.e., the chain has become stationary), the limiting distribution is:

$$\lim_{k \rightarrow \infty} \mathbf{f}(n+k) = \lim_{k \rightarrow \infty} (\mathbf{P}^T)^k \mathbf{f}(n) = \gamma \mathbf{u} \mathbf{u}^T \mathbf{f}(n) = \gamma' \mathbf{u} \mathbf{u}^T \mathbf{u} = \gamma' \mathbf{u}$$

- The above is an intuitive proof of the fact that, for MC admitting a stationary distribution, such a distribution coincides with the limiting distribution, i.e.:

$$\lim_{n \rightarrow \infty} \mathbf{f}(n) \propto \mathbf{u}$$

Entropy Rate of a Markov Chain

- Let X_n be an MC on $\{1, \dots, M\}$, denote $\mathbf{P}$ its transition matrix, and assume it admits a stationary distribution;
- The entropy rate can be easily calculated as:

$$H(\mathcal{X}) = \lim_{n \rightarrow \infty} H(X_n | \mathbf{X}^{n-1}) = \lim_{n \rightarrow \infty} H(X_n | X_{n-1})$$

- Since

$$\begin{aligned} H(X_n | X_{n-1}) &= \sum_{i=1}^M \sum_{j=1}^M f_{X_n, X_{n-1}}(i, j) \log \frac{1}{f_{X_n | X_{n-1}}(i | j)} = \sum_{j=1}^M f_{X_{n-1}}(j) \\ &\quad \sum_{i=1}^M f_{X_n | X_{n-1}}(i | j) \log \frac{1}{f_{X_n | X_{n-1}}(i | j)} = \sum_{j=1}^M f_{X_{n-1}}(j) \sum_{i=1}^M p_{j,i} \log \frac{1}{p_{j,i}} \end{aligned}$$

taking the limit, we obtain

$$H(\mathcal{X}) = \sum_{j=1}^M \sum_{i=1}^M u_j p_{j,i} \log \frac{1}{p_{j,i}}$$

with $\mathbf{u}$ the limiting distribution.

An example: a simple coding scheme

- Assume we have a Bernoulli process $B_n \in \{0, 1\}$, with $f_{B_n}(1) = p$;
- We want to avoid two consecutive zeros, whereby we encode it by inserting a 1 after a zero.
- As a consequence, X_n can have arbitrarily long streams of ones, but not consecutive zeros;
- We want to determine the entropy rate of the process X_n .
- Let us first notice that everything goes as described in the state diagram of Figure 2: from state $X_{n-1} = 0$ we necessarily go to state $X_n = 1$, while from state $X_{n-1} = 1$ we can go both ways.




Figura 2: State-space representation of the encoding process

An example: a simple coding scheme - cont'd

- The encoding process is thus a Markov chain with

$$P = \begin{bmatrix} 0 & 1 \\ 1-p & p \end{bmatrix} \quad u = \begin{bmatrix} \frac{1-p}{2-p} \\ \frac{1}{2-p} \end{bmatrix} \quad H(\mathcal{X}) = \frac{H_2(p, 1-p)}{2-p} = \frac{H(p)}{2-p}$$

- One might choose p as the maximizer of $H(\mathcal{X})$, i.e.:

$$p_* = 0.618 \implies H_*(\mathcal{X}) = 0.6942$$

- Notice that the maximizing value of p tends to bring the chain in state "1", since when the chain is in state "0" there is no uncertainty on its evolution;
- The original process B_n has an entropy rate $H(p)$ bits/symbol, while the encoding reduces the value informational value of each symbol to $\frac{H(p)}{2-p}$;
- Interestingly, while - for $p = \frac{1}{2}$ - B_n carries 1 bit of information per bit, the maximum that the encoded process can carry is 0.6942 bits of information per bit: this is the essence of "channel coding".

Slackening the condition....

- Assume now that we want to prevent more than two consecutive zeros (i.e., a less stringent condition);
- Define the state of the chain as the pair $S_{n-1} = (X_{n-1}, X_{n-2})$, whereby the allowed states are 00, 01, 10 and 11: see the transition table below and the state diagram of Figure 3.

S_{n-1}	B_n	X_n	S_n
00	0/1	1	10
01	0	0	00
01	1	1	10
10	0	0	01
10	1	1	11
11	0	0	01
11	1	1	11




Figura 3: State-space representation of the slackened encoding process

The slackened code

- The transition matrix and the stationary distribution are:

$$P = \begin{pmatrix} 0 & 0 & 1 & 0 \\ 1-p & 0 & p & 0 \\ 0 & 1-p & 0 & p \\ 0 & 1-p & 0 & p \end{pmatrix} \quad u = \frac{1}{p^2 - 3p + 3} \begin{pmatrix} (1-p)^2 \\ 1-p \\ 1-p \\ p \end{pmatrix}$$


- Thus the entropy rate is

$$H(\mathcal{X}) = \frac{2-p}{p^2 - 3p + 3} H(p)$$

- Question: leaving aside the analytic study of this function, does "slackening" the constraint translate in "freer" X_n and - ultimately - in the possibility of having more information per bit in the encoded stream?
- Answer: see Figure in next slide.

The entropy rate of the slackened code

- The entropy rate attains now values which were prohibited in the previous, "overconstrained" case;
- An optimal choice of p , i.e. $p \simeq 0.58$, allows attaining an entropy rate $\simeq 0.873$, thus somehow "restoring" the informational value of a bit;
- Summing up, more freedom means more entropy and thus more information.



Alcuni commenti sulle variabili continue

- Ricordiamo che una variabile continua X è caratterizzabile attraverso la sua densità di probabilità $f_X(x)$ che **non è una probabilità**.
- Di conseguenza, la quantità

$$\log \frac{1}{f_X(x)}$$

non è a rigore interpretabile come una misura di informazione.

- Infatti ricordiamo che ogni variabile continua assume con probabilità nulla ogni singolo valore del suo alfabeto.

Problema

Come possiamo definire gli equivalenti di entropia, entropia congiunta ed entropia condizionale per variabili continue?

Prima soluzione: un approccio "intuitivo"

- La soluzione più naturale è "estendere brutalmente" la definizione di entropia a quella di "entropia differenziale":

$$h(X) = \int_{-\infty}^{\infty} f_X(x) \log \frac{1}{f_X(x)} dx$$

dove $f_X(x)$ è la densità di probabilità della variabile **continua** X .

- Si noti tuttavia che:
 - † La densità di probabilità **non** è una probabilità;
 - † Pertanto la quantità $\log \frac{1}{f_X(x)}$ **non è** interpretabile come una misura di informazione;
 - † Di conseguenza $h(X)$ **non rappresenta** un'entropia nel senso introdotto per le variabili discrete: basti pensare che essa può essere negativa, e che una condizione di entropia differenziale nulla non indica una mancanza di incertezza.

Esempio: La variabile uniforme

- Supponiamo che $X \sim \mathcal{U}(a, b)$, cioè:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrove} \end{cases}$$

- Applicando la definizione della slide precedente, avremo:

$$h(X) = \log(b-a) \begin{cases} > 0 & b-a > 1 \\ = 0 & b-a = 1 \\ < 0 & 0 \leq b-a < 1 \end{cases}$$

- Si noti che la condizione $h(X) = 0$ implica che X è uniforme in un intervallo di ampiezza unitario, ma non che essa è deterministica (costante);
- Si noti che se $0 \leq b-a \leq 1$ (per esempio, $a = \frac{1}{4}$ e $b = \frac{3}{4}$), $h(X) < 0$.
- La condizione di X costante corrisponde invece a $h(X) = -\infty$ ($a = b$).

...Tuttavia...

- Con le precedenti avvertenze, $h(X)$ si può ancora considerare una misura della quantità media di informazione associata alla variabile aleatoria X ;
- In modo del tutto analogo, possiamo definire le "estensioni":

$$h(X, Y) = \int \int dx dy f_{X,Y}(x, y) \log \frac{1}{f_{X,Y}(x, y)} dx dy$$

$$h(X|Y) = \int \int dx dy f_{X,Y}(x, y) \log \frac{1}{f_{X|Y}(x|y)} dx dy$$

$$h(Y|X) = \int \int dx dy f_{X,Y}(x, y) \log \frac{1}{f_{Y|X}(y|x)} dx dy$$

Una giustificazione più rigorosa

- Abbiamo visto che la mutua informazione tra due variabili aleatorie misura il loro grado di dipendenza statistica ed è infatti pari alla divergenza tra la loro congiunta e il prodotto delle marginali;
- Per variabili continue, la condizione di indipendenza si scrive nella nota forma $f_{X,Y}(x,y) = f_X(x)f_Y(y)$, per cui possiamo definire la mutua informazione tra X e Y in modo "naturale":

$$i(X; Y) = D(f_{X,Y}(x,y) \parallel f_X(x)f_Y(y)) = \mathbb{E} \left[\log \frac{f_{X,Y}(X, Y)}{f_X(X)f_Y(Y)} \right]$$

dove la media va eseguita assumendo che la congiunta sia $f_{X,Y}(x,y)$.

- Applicheremo di seguito i risultati delle slides 19 e 20.

Entropia differenziale: definizioni

- Dalla slide 67 e dalla legge di Bayes per le densità di probabilità otteniamo:

$$\begin{aligned} i(X; Y) &= \mathbb{E} \left[\log \frac{f_{X,Y}(X, Y)}{f_X(X)f_Y(Y)} \right] = \mathbb{E} \left[\log \frac{f_{X|Y}(X|Y)}{f_X(X)} \right] = \\ &= \mathbb{E} \left[\log \frac{1}{f_X(X)} \right] - \mathbb{E} \left[\log \frac{1}{f_{X|Y}(X|Y)} \right] = h(X) - h(X|Y) \end{aligned}$$

dove, in perfetta coerenza con il caso continuo, abbiamo:

$$\begin{aligned} h(X) &= \mathbb{E} \left[\log \frac{1}{f_X(X)} \right] = \int f_X(x) \log \frac{1}{f_X(x)} dx \\ h(X|Y) &= \mathbb{E} \left[\log \frac{1}{f_{X|Y}(X|Y)} \right] = \int \int f_{X,Y}(x, y) \log \frac{1}{f_{X|Y}(x|y)} dx dy \end{aligned}$$

- Si noti che - operando diversamente - avremmo

$$i(X; Y) = h(Y) - h(Y|X)$$

Alcune conseguenze

- Dal momento che la divergenza è non negativa, anche per le variabili aleatorie il condizionamento non aumenta l'entropia, cioè:

$$h(X) \geq h(X|Y) \quad h(Y) \geq h(Y|X)$$

dove l'uguaglianza implica indipendenza statistica.

- Dal momento che (vedi slide 43):

$$\begin{aligned} i(X; Y) &= \mathbb{E} \left[\log \frac{1}{f_X(X)} \right] + \mathbb{E} \left[\log \frac{1}{f_Y(Y)} \right] - \mathbb{E} \left[\log \frac{1}{f_{X,Y}(X, Y)} \right] \\ &= h(X) + h(Y) - \mathbb{E} \left[\log \frac{1}{f_{X,Y}(X, Y)} \right] \end{aligned}$$

la quantità $h(X, Y) = \mathbb{E} \left[\log \frac{1}{f_{X,Y}(X, Y)} \right]$ è legittimamente interpretabile come entropia congiunta;

- Inoltre, si ricava facilmente la validità della regola della catena:

$$h(X, Y) = h(X) + h(Y|X) = h(Y) + h(X|Y)$$

Entropia differenziale di variabili Gaussiane

- Sia $X \sim \mathcal{N}(\mu, \sigma^2)$, cioè:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right], \quad x \in \mathbb{R}$$

- Applichiamo la definizione per calcolare $h(X)$ (in nat):

$$\begin{aligned} h(X) &= \mathbb{E} \left[\ln \sqrt{2\pi\sigma^2} \right] + \mathbb{E} \left[\frac{(X - \mu)^2}{2\sigma^2} \right] = \\ &= \frac{1}{2} \ln 2\pi\sigma^2 + \frac{1}{2\sigma^2} \overbrace{\mathbb{E} [(X - \mu)^2]}^{\sigma^2} = \frac{1}{2} \ln(2\pi e\sigma^2) \end{aligned}$$

- Si noti che una variabile Gaussiana deterministica ($\sigma^2 = 0$) dà ancora una volta luogo a $h(X) = -\infty$; la media è inoltre **irrilevante** ai fini dell'entropia.
- Si noti anche che $h(X)$ è crescente con σ^2 e **non limitata**.

Coppie di variabili Gaussiane

- Siano $\mathbf{X} = [X_1 X_2]^T$ una coppia di variabili Gaussiane con matrice di covarianza $\mathbf{K}$ (vedi slide 128 del blocco 1), che assumiamo a media nulla in quanto irrilevante, per cui la loro pdf congiunta è:

$$f_{\mathbf{X}}(x_1, x_2) = f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{2\pi|\mathbf{K}|^{1/2}} \exp\left(-\frac{1}{2}\mathbf{x}^T \mathbf{K}^{-1} \mathbf{x}\right), \quad \mathbf{x} \in \mathbb{R}^2$$

- Applicando la definizione avremo

$$h(\mathbf{X}) = \frac{1}{2} \ln 2\pi|\mathbf{K}| + \frac{1}{2} \mathbb{E} [\mathbf{X}^T \mathbf{K}^{-1} \mathbf{X}] = \frac{1}{2} \ln 2\pi e^2 |\mathbf{K}|$$

dove le ultime due relazioni si possono rigorosamente dimostrare.